```
#Importation de la librairie Pandas
In [2]:
         import pandas as pd
         import numpy as np
         import datetime as dt
         import matplotlib
         import matplotlib.pyplot as plt
         import seaborn as sns
         import plotly.express as px
         import plotly.graph_objects as go
         from plotly.subplots import make_subplots
         import missingno as msno
         import scipy.stats as st
In [3]:
         # import et lecture export ERP
         erp_df = pd.read_excel('Fichier_erp.xlsx')
         erp_df.head()
         c:\Python311\Lib\site-packages\openpyx1\worksheet\_reader.py:329: UserWarning: Unknown e
         xtension is not supported and will be removed
           warn(msg)
Out[3]:
           product id onsale web price stock quantity stock status
         0
                3847
                                  24.2
                                                  0
                                                       outofstock
                               1
         1
                3849
                                  34.3
                                                  0
                                                       outofstock
         2
                3850
                               1
                                  20.8
                                                  0
                                                       outofstock
         3
                4032
                               1
                                  14.1
                                                  n
                                                       outofstock
         4
                4039
                                  46.0
                                                  0
                                                       outofstock
In [4]:
         # import et lecture export BDD Web
         web_df = pd.read_excel('Fichier_web.xlsx')
         web_df.head()
         c:\Python311\Lib\site-packages\openpyxl\worksheet\_reader.py:329: UserWarning: Unknown e
         xtension is not supported and will be removed
           warn(msg)
             sku virtual downloadable rating_count average_rating total_sales tax_status tax_class post_author |
Out[4]:
         0 16004
                      0
                                   0
                                               0
                                                           0.0
                                                                      5.0
                                                                               NaN
                                                                                         NaN
                                                                                                     2.0
             NaN
                      0
                                                           NaN
                                                                     NaN
                                                                               NaN
                                                                                         NaN
                                                                                                    NaN
         2 15075
                      0
                                   0
                                               0
                                                           0.0
                                                                      3.0
                                                                                                     2.0
                                                                             taxable
                                                                                         NaN
         3 16209
                      0
                                   0
                                               0
                                                           0.0
                                                                      6.0
                                                                                                     2.0
                                                                             taxable
                                                                                         NaN
         4 15763
                                                           0.0
                                                                      1.0
                                                                                                     2.0
                                                                               NaN
                                                                                         NaN
```

```
# lecture du dataset liaisons
In [5]:
         liaisons_ = pd.read_excel('fichier_liaison.xlsx')
         liaisons_
         c:\Python311\Lib\site-packages\openpyxl\worksheet\_reader.py:329: UserWarning: Unknown e
         xtension is not supported and will be removed
           warn(msg)
             product_id id_web
Out[5]:
           0
                  3847
                         15298
           1
                  3849
                         15296
           2
                  3850
                         15300
           3
                  4032
                         19814
           4
                  4039
                         19815
          ...
         820
                  7203
                           NaN
         821
                  7204
                           NaN
         822
                  7247 13127-1
         823
                  7329
                        14680-1
         824
                  7338
                         16230
        825 rows × 2 columns
In [6]:
         # dimensions du fichier ERP
         print(f"The ERP dataset has {erp_df.shape[0]} rows and {erp_df.shape[1]} columns")
         The ERP dataset has 825 rows and 5 columns
         # dimensions du fichier WEB
In [7]:
         print(f"The WEB dataset has {web_df.shape[0]} rows and {web_df.shape[1]} columns")
         The WEB dataset has 1513 rows and 28 columns
         # dimensions du fichier ERP
In [8]:
         print(f"The liaisons dataset has {liaisons_.shape[0]} rows and {liaisons_.shape[1]} colu
         The liaisons dataset has 825 rows and 2 columns
         web_df = web_df.rename(columns={'sku': 'id_web'})
In [9]:
         web_df.sample(20)
              id_web virtual downloadable rating_count average_rating total_sales tax_status tax_class post_auth
Out[9]:
          526
               16057
                          0
                                       0
                                                   0
                                                               0.0
                                                                         0.0
                                                                                taxable
                                                                                            NaN
          818
               15440
                          0
                                       0
                                                   0
                                                               0.0
                                                                         0.0
                                                                                  NaN
                                                                                            NaN
         1012
                                       0
                                                   0
               12585
                          0
                                                               0.0
                                                                        12.0
                                                                                taxable
                                                                                            NaN
         1155
               13754
                          0
                                                               0.0
                                                                         0.0
                                                                                taxable
                                                                                            NaN
```

2	NaN	taxable	0.0	0.0	0	0	0	15688	1116
2	NaN	taxable	3.0	0.0	0	0	0	14944	176
2	NaN	NaN	0.0	0.0	0	0	0	15677	998
2	NaN	NaN	0.0	0.0	0	0	0	12641	813
2	NaN	taxable	0.0	0.0	0	0	0	16296	773
2	NaN	NaN	3.0	0.0	0	0	0	15668	1146
2	NaN	taxable	0.0	0.0	0	0	0	15185	364
2	NaN	NaN	8.0	0.0	0	0	0	16256	1017
2	NaN	NaN	0.0	0.0	0	0	0	15240	230
2	NaN	taxable	0.0	0.0	0	0	0	15399	1377
2	NaN	NaN	7.0	0.0	0	0	0	15428	259
Na	NaN	NaN	NaN	NaN	0	0	0	NaN	193
2	NaN	taxable	0.0	0.0	0	0	0	14596	564
2	NaN	taxable	0.0	0.0	0	0	0	11996	565
2	NaN	taxable	0.0	0.0	0	0	0	15704	1199

```
493
                NaN
                                                           NaN
                                                                     NaN
                                                                              NaN
                                                                                       NaN
                                                                                                 Na
        20 rows × 28 columns
In [10]:
         # types des colonnes
         erp_df.info()
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 825 entries, 0 to 824
         Data columns (total 5 columns):
          #
                              Non-Null Count
              Column
                                               Dtype
          0
              product_id
                              825 non-null
                                               int64
          1
              onsale_web
                              825 non-null
                                               int64
          2
              price
                              825 non-null
                                               float64
          3
              stock_quantity 825 non-null
                                               int64
                              825 non-null
              stock_status
                                               object
         dtypes: float64(1), int64(3), object(1)
         memory usage: 32.4+ KB
In [11]:
         # types des colonnes
         web_df.info()
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 1513 entries, 0 to 1512
         Data columns (total 28 columns):
              Column
                                     Non-Null Count Dtype
         - - -
              -----
                                      -----
          0
              id web
                                     1428 non-null
                                                      obiect
          1
              virtual
                                     1513 non-null
                                                      int64
          2
              downloadable
                                     1513 non-null
                                                      int64
          3
              rating_count
                                     1513 non-null
                                                      int64
          4
              average_rating
                                     1430 non-null
                                                      float64
          5
              total_sales
                                     1430 non-null
                                                      float64
          6
                                     716 non-null
                                                      object
              tax_status
          7
              tax_class
                                     0 non-null
                                                      float64
          8
                                     1430 non-null
                                                      float64
              post_author
                                                      datetime64[ns]
          9
              post_date
                                     1430 non-null
          10
             post_date_gmt
                                     1430 non-null
                                                      datetime64[ns]
          11 post_content
                                     0 non-null
                                                      float64
          12 post_title
                                     1430 non-null
                                                      object
          13 post_excerpt
                                     716 non-null
                                                      object
          14
              post_status
                                     1430 non-null
                                                      object
          15 comment_status
                                     1430 non-null
                                                      object
          16 ping_status
                                     1430 non-null
                                                      object
          17
                                     0 non-null
                                                      float64
              post_password
          18
              post_name
                                     1430 non-null
                                                      object
          19 post_modified
                                     1430 non-null
                                                      datetime64[ns]
                                     1430 non-null
             post_modified_gmt
                                                      datetime64[ns]
             post_content_filtered 0 non-null
          21
                                                      float64
          22
             post_parent
                                     1430 non-null
                                                      float64
          23 guid
                                     1430 non-null
                                                      object
          24
              menu_order
                                     1430 non-null
                                                      float64
          25
              post_type
                                     1430 non-null
                                                      object
                                     714 non-null
          26
                                                      object
              post_mime_type
              comment_count
                                     1430 non-null
                                                      float64
         dtypes: datetime64[ns](4), float64(10), int64(3), object(11)
         memory usage: 331.1+ KB
         liaisons_.info()
```

In [12]: <class 'pandas.core.frame.DataFrame'>

RangeIndex: 825 entries, 0 to 824 Data columns (total 2 columns): Column Non-Null Count Dtype

```
0
              product_id 825 non-null
                                           int64
              id_web 734 non-null
                                           object
         dtypes: int64(1), object(1)
         memory usage: 13.0+ KB
         Vérifier les doublons
         #liaisons_.loc[liaisons_['id_web'].duplicated(keep=False),:]
In [13]:
         len(liaisons_.loc[liaisons_['product_id'].duplicated(keep=False),:])
Out[13]:
         #liaisons_.loc[liaisons_['id_web'].duplicated(keep=False),:]
         len(liaisons_.loc[liaisons_['id_web'].duplicated(keep=False),:])
Out[14]:
         len(erp_df.loc[erp_df['product_id'].duplicated(keep=False),:])
Out[15]:
         len(web_df.loc[web_df['id_web'].duplicated(keep=False),:])
In [16]:
         1513
Out[16]:
         comparison = web_df.loc[web_df['id_web'] == 16209]
In [17]:
         comparison[['id_web','total_sales','post_name','tax_status','post_type','post_mime_type'
             id_web total_sales
Out[17]:
                                           post_name tax_status
                                                               post_type post_mime_type
              16209
                              maurel-cabardes-tradition-2017
                                                        taxable
                                                                                  NaN
                                                                 product
         13
              16209
                                                                             image/jpeg
                          6.0 maurel-cabardes-tradition-2017
                                                          NaN attachment
         # Vérifier si les valeurs 'string' sont dans les 2 exports
In [18]:
         differentes_valeurs_liaisons = liaisons_['id_web'].unique()
         # Affichez les différentes valeurs
         print(differentes_valeurs_liaisons)
         [15298 15296 15300 19814 19815 15303 14975 16042 14980 16041 15269 14977
          16044 16043 16449 16045 16030 13127 19816 nan 16029 16039 16318 16275
          16498 16320 16319 15966 15022 15967 15490 16416 11862 15444 15953 12045
          13074 15941 16069 13072 15440 13435 13078 13117 16296 16014 16462 16013
          16180 15676 16120 15564 15675 15378 15813 13416 14905 15767 16505 15683
          16504 15787 14800 15353 15382 15339 11668 13209 15341 13217 304 11641
          1662 1360 15648 1364 7086 1366 15140 16238 16237 15141 14944 14941 14751
          16093 15668 15373 15375 14474 15482 13453 15075 16124 15785 15784 15786
          14332 16210 16211 16209 15629 15583 16160 16166 15783 16560 15747 15746
          16190 16189 16265 16191 16263 15605 16529 15441 13032 16256 16322 16295
          15656 15655 15415 15414 15413 16023 16024 15720 15714 15717 15718 15480
          15213 15672 12599 15758 15829 15759 16585 15306 16497 15261 12657 15403
          15461 16269 13905 16567 15436 14725 15310 15770 16097 15428 15033 16317
          15032 6616 12203 14253 12476 14485 14945 15662 15663 15664 15665 15136
          16537 16307 16244 15839 13460 13089 12942 14864 14527 14865 15690 16330
          16154 16153 16066 16065 15292 13771 16246 16501 16578 15567 16553 13172
          15120 15949 15946 7818 13599 4679 12586 12588 15940 12587 12589 12585
          9562 13854 13853 11585 11467 11586 13765 13766 11587 9636 12639 12641
          12640 14768 3506 3510 3507 13230 7819 3509 15426 15621 15457 15065 13604
          12857 14785 15476 14000 15478 15475 16151 15659 15147 15660 15148 15149
          15146 15145 15801 15452 15038 15030 15875 16186 14371 10459 14372 11049
          15850 15849 812 807 805 802 2534 793 791 2179 804 41 798 2361 15848 16525
```

```
16262 16261 15206 11849 13515 13514 13516 10814 11847 13517 16081 15402
          15404 13647 14657 16053 15525 15527 14676 16057 16056 13762 15280 15282
          15281 15283 15934 15933 15575 16239 14451 16324 15582 13736 13659 15465
          15004 14699 15349 15466 14700 10775 16119 15667 14746 15361 15196 15657
          15658 15670 16527 16513 15880 15879 16010 14950 16540 15729 38 5646 8344
          15576 16138 14366 13412 12601 14632 15315 13627 14184 15429 16132 14680
          15859 16229 14302 16072 14300 13096 16564 13754 15734 15448 15881 15731
          15316 15732 14599 15733 15730 12771 3568 14506 15811 16342 16292 15307
          16047 16255 15154 16274 16148 14360 16149 16289 14981 15773 15776 16037
          16038 15807 15952 15808 16062 16063 14802 13052 14805 14220 14374 14395
          15614 13809 15612 13814 15613 15615 15533 15531 15530 15608 15586 15928
          16276 16277 15456 15425 15047 15927 16155 16280 9937 16281 15554 15106
          16283 13379 15338 15337 'bon-cadeau-25-euros' 15737 15958 16515 16586
          11225 16004 14756 16005 14930 13313 15229 14507 14509 14508 15868 14581
          14580 15869 15871 15870 12791 11602 15073 14839 15272 14696 15630 11996
          13914 13913 11997 531 13531 15711 15713 15715 15346 15345 15344 15755
          15677 14561 16022 16011 3383 14149 13904 14141 12494 15462 15095 14626
          12496 12315 15649 14809 15155 12194 16328 14469 16034 14679 15526 16305
          16306 15138 15753 15756 16131 16130 16129 14712 15481 16146 14648 14192
          15860 15863 15861 15862 15864 14819 14828 14827 15202 13959 13965 13958
          13957 13520 13969 14715 19820 19821 15748 19822 16192 14730 14729 8463
          13982 15944 15930 14912 15945 14915 14855 14856 15923 14845 14844 15921
          15922 12366 8365 12365 14647 15812 14661 16304 15797 16094 14736 11736
          15036 15360 15674 13557 15035 16121 14241 14982 15026 15116 15369 15566
          16003 15127 15125 14323 15631 16147 7033 11258 13849 15818 15179 15185
          15183 15254 15178 15184 15180 15264 14338 15561 16213 14692 13291 13895
          15688 14461 14689 11277 15399 13572 14955 13567 15471 15080 14429 15238
          15237 14600 15241 11933 15240 15325 15328 15329 15775 15774 14983 13910
          16539 15910 12339 12869 14095 14099 15856 12881 15857 12882 15227 10014
          14265 14774 14775 14773 15343 15351 16323 523 15432 16472 14379 15609
          14377 15895 13577 15577 15766 15892 16326 15574 13662 11669 13215 13211
          15342 15318 13073 16159 16264 14899 15134 16133 16028 15951 15487 15486
          15489 15529 14089 14100 14092 14090 14106 14101 14797 15201 14923 14573
          14569 14570 15834 14596 15126 14604 16565 16580 16077 13996 15072 11601
          12790 15070 16096 7032 15324 15162 15161 15163 16273 16247 15654 15710
          15745 15678 15810 15779 15707 15705 15706 15704 15473 15479 15647 15769
          15434 15764 16071 15781 16031 15539 16046 15204 15205 15790 15791 15792
          15793 15795 15794 15763 16152 15661 16068 16067 8193 16144 15256 15735
          14897 15736 15740 15845 15741 16135 15891 15887 '13127-1' '14680-1' 16230]
In [19]: # Filtrer les chaînes de caractères
         chaines = [str(val) for val in web_df['id_web'].unique() if isinstance(val, str)]
         # Afficher la liste des chaînes de caractères
         print(chaines)
         ['bon-cadeau-25-euros', '13127-1']
In [20]:
         # Filtrer les chaînes de caractères
         chaines = [str(val) for val in liaisons_['id_web'].unique() if isinstance(val, str)]
         # Afficher la liste des chaînes de caractères
         print(chaines)
         ['bon-cadeau-25-euros', '13127-1', '14680-1']
In [21]: # Vérifier si les valeurs 'string' sont dans les 2 exports
         differentes_valeurs_id_web = web_df['id_web'].unique()
         # Affichez les différentes valeurs
         print(len(differentes_valeurs_id_web))
         715
```

In [22]: differentes\_valeurs\_product\_id = erp\_df['product\_id'].unique()

```
# méthode .isna() pour obtenir la somme des valeurs manquantes pour chaque colonne
In [23]:
         web_df.isna().sum()
         id_web
                                      85
Out[23]:
                                       0
         virtual
                                       0
         downloadable
         rating_count
                                       0
         average_rating
                                     83
                                     83
         total_sales
                                     797
         tax_status
                                   1513
         tax_class
         post_author
                                     83
                                     83
         post_date
         post_date_gmt
                                     83
                                   1513
         post_content
                                     83
         post_title
         post_excerpt
                                     797
         post_status
                                     83
         comment_status
                                     83
                                     83
         ping_status
                                   1513
         post_password
         post_name
                                     83
                                     83
         post_modified
         post_modified_gmt
                                      83
                                   1513
         post_content_filtered
                                     83
         post_parent
         guid
                                     83
                                     83
         menu_order
         post_type
                                     83
                                     799
         post_mime_type
                                     83
         comment_count
         dtype: int64
         # pour afficher uniquement les variables qui ont des valeurs manquantes
In [24]:
          nb_na = web_df.isnull().sum()
          nb_na[nb_na>0]
                                     85
         id_web
Out[24]:
                                     83
         average_rating
         total_sales
                                      83
         tax_status
                                     797
         tax_class
                                   1513
         post_author
                                     83
         post_date
                                      83
                                     83
         post_date_gmt
                                   1513
         post_content
         post_title
                                     83
                                     797
         post_excerpt
         post_status
                                     83
                                     83
         comment_status
                                     83
         ping_status
         post_password
                                   1513
                                     83
         post_name
                                     83
         post_modified
         post_modified_gmt
                                     83
         post_content_filtered
                                   1513
         post_parent
                                     83
                                     83
         guid
                                     83
         menu_order
         post_type
                                      83
                                     799
         post_mime_type
```

# Affichez les différentes valeurs

print(len(differentes\_valeurs\_product\_id))

```
dtype: int64
          # méthode .isna() pour obtenir la somme des valeurs manquantes pour chaque colonne
In [25]:
          erp_df.isna().sum()
          product_id
Out[25]:
          onsale_web
                             0
          price
                             0
                             0
          stock_quantity
          stock_status
          dtype: int64
In [26]:
          # méthode .isna() pour obtenir la somme des valeurs manquantes pour chaque colonne
          liaisons_.isna().sum()
          product_id
                          0
Out[26]:
          id_web
                         91
          dtype: int64
          # pour afficher uniquement les variables qui ont des valeurs manquantes
In [27]:
          nb_na = liaisons_.isnull().sum()
          nb_na[nb_na>0]
          id_web
Out[27]:
          dtype: int64
          # filtrer web_df sur 'product'
In [28]:
          web_df = web_df[web_df['post_type'] == 'product']
          web_df.head()
            id_web virtual downloadable rating_count average_rating total_sales tax_status tax_class post_author
Out[28]:
                                                             0.0
          2
              15075
                        0
                                     0
                                                 0
                                                                        3.0
                                                                               taxable
                                                                                           NaN
                                                                                                       2.0
             16209
                        0
                                     0
                                                 0
                                                             0.0
                                                                        6.0
                                                                               taxable
                                                                                                       2.0
                                                                                          NaN
                        0
                                     0
                                                 0
                                                             0.0
                                                                        0.0
                                                                                                       2.0
              13895
                                                                                          NaN
                                                                               taxable
             12857
                        0
                                     0
                                                 0
                                                             0.0
                                                                        0.0
                                                                                                       2.0
                                                                               taxable
                                                                                           NaN
              14106
                                     0
                                                 0
                                                             0.0
                                                                        0.0
                                                                               taxable
                                                                                          NaN
                                                                                                       2.0
         5 rows × 28 columns
          # pour afficher uniquement les variables qui ont des valeurs manquantes
In [29]:
          nb_na = web_df.isnull().sum()
          nb_na[nb_na>0]
```

83

comment\_count

id\_web

tax\_class

Out[29]:

2

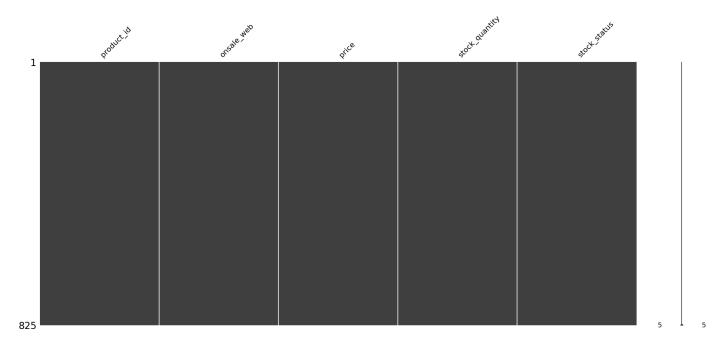
716

post\_content 716 post\_password 716 post\_content\_filtered 716 post\_mime\_type 716

dtype: int64

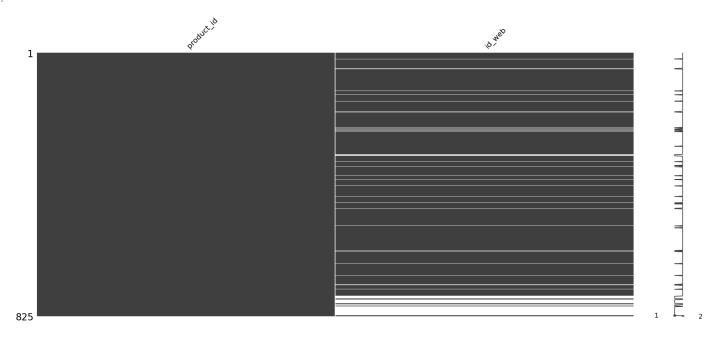
In [30]: msno.matrix(erp\_df)

Out[30]: <Axes: >



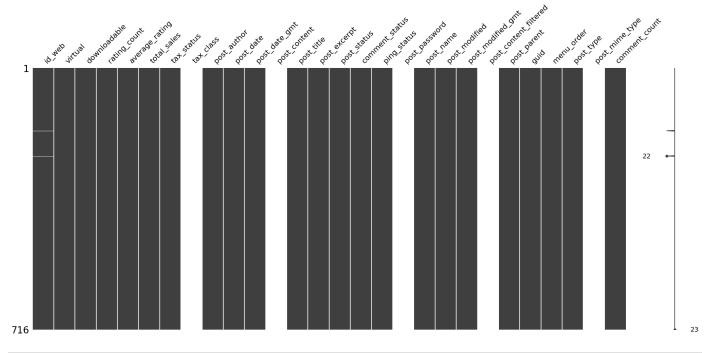
In [31]: msno.matrix(liaisons\_)

Out[31]: <Axes: >



In [32]: msno.matrix(web\_df)

Out[32]: <Axes: >

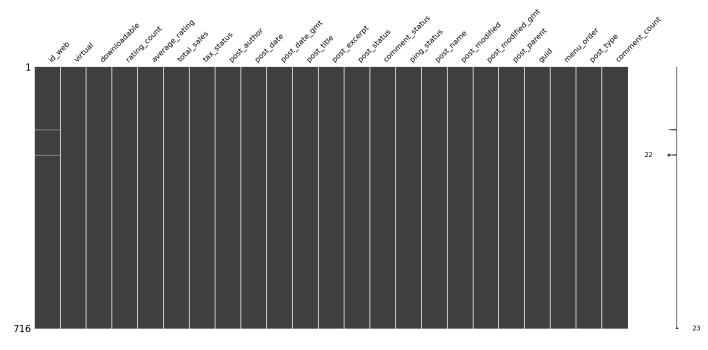


In [33]: # suppression des colonnes vides
web\_df = web\_df.drop(['tax\_class','post\_content','post\_password','post\_content\_filtered'

In [34]: # Vérificiation visuelle avec le package missingno
msno.matrix(web\_df)

Out[34]: <Axes: >

Out[35]:



In [35]:	<pre>web_df.loc[web_df['id_web'].isnull(),:]</pre>
----------	--

	id_web	virtual	downloadable	rating_count	average_rating	total_sales	tax_status	post_author	post_dat
353	NaN	0	0	0	0.0	3.0	taxable	2.0	2018-04 C 11:23:4
488	NaN	0	0	0	0.0	10.0	taxable	2.0	2018-0 <sup>°</sup> 3 12:07:2

```
web_df.info()
In [36]:
          <class 'pandas.core.frame.DataFrame'>
          Index: 716 entries, 2 to 1510
          Data columns (total 23 columns):
                                    Non-Null Count
               Column
           #
                                                      Dtype
          - - -
               ----
                                     -----
                                                      ----
           0
               id_web
                                    714 non-null
                                                      object
               virtual
           1
                                    716 non-null
                                                      int64
           2
               downloadable
                                    716 non-null
                                                      int64
           3
               rating_count
                                    716 non-null
                                                      int64
           4
               average_rating
                                    716 non-null
                                                      float64
           5
               total_sales
                                    716 non-null
                                                      float64
           6
               tax_status
                                    716 non-null
                                                      object
           7
               post_author
                                    716 non-null
                                                      float64
           8
                                    716 non-null
                                                      datetime64[ns]
               post_date
           9
               post_date_gmt
                                    716 non-null
                                                      datetime64[ns]
           10 post_title
                                    716 non-null
                                                      object
               post_excerpt
           11
                                    716 non-null
                                                      object
                                    716 non-null
                                                      object
           12
               post_status
           13 comment_status
                                    716 non-null
                                                      object
           14 ping_status
                                    716 non-null
                                                      object
                                    716 non-null
           15 post_name
                                                      object
           16
               post_modified
                                    716 non-null
                                                      datetime64[ns]
           17
               post_modified_gmt 716 non-null
                                                      datetime64[ns]
           18
                                    716 non-null
                                                      float64
               post_parent
           19
               guid
                                    716 non-null
                                                      object
           20
                                    716 non-null
                                                      float64
               menu_order
           21
                                    716 non-null
                                                      object
               post_type
               comment_count
                                    716 non-null
                                                      float64
          dtypes: datetime64[ns](4), float64(6), int64(3), object(10)
          memory usage: 134.2+ KB
          web_df = web_df.dropna(subset=['id_web'])
In [37]:
          msno.matrix(web_df)
In [38]:
          <Axes: >
Out[38]:
                                                                            Dost modified drift
                                                             connent status
                                               Poet date drit
                                                                         Post modified
                                                      post etcerpt
                                        Post author
                                                          post status
                                                                 ping status
                                    vat status
                                total sales
                                           post date
                                                                     post name
                                                                                           Post Whe
                                                                                post pareni
                                                   Post title
              id meb
                  virtual
```

Jointure des 2 exports : ERP et CMS

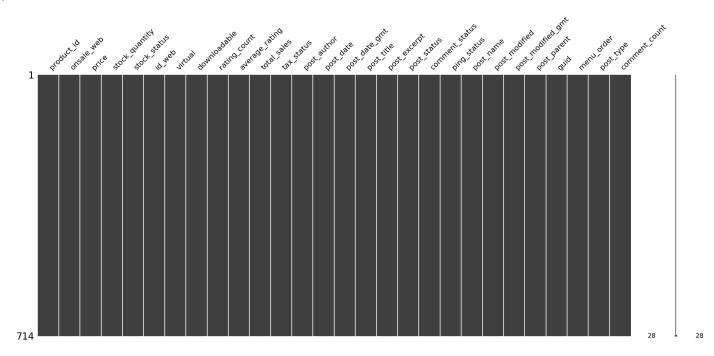
In [39]:	mer	nerging_erp_web = erp_df.merge(liaisons_, how='inner', on='product_id')									
In [40]:	mer	erging_erp_web2 = merging_erp_web.merge(web_df, how='inner', on='id_web')									
In [41]:	mer	erging_erp_web2.head()									
Out[41]:	I	product_id	onsale_web	price	stock_quantity	stock_status	id_web	virtual	downloadable	rating_count	a۱
	0	3847	1	24.2	0	outofstock	15298	0	0	0	
	1	3849	1	34.3	0	outofstock	15296	0	0	0	
	2	3850	1	20.8	0	outofstock	15300	0	0	0	
	3	4032	1	14.1	0	outofstock	19814	0	0	0	
	4	4039	1	46.0	0	outofstock	19815	0	0	0	

5 rows × 28 columns

Visuel du dataframe nettoyé avec jointure

In [42]: msno.matrix(merging\_erp\_web2)

Out[42]: <Axes: >



```
Calcul du chiffres d'affaires = 70 568,60 EUR
            merging_erp_web2["C.A."] = (merging_erp_web2['price'] * merging_erp_web2['total_sales'])
In [44]:
            CA_total = merging_erp_web2['C.A.'].sum().round(1)
In [45]:
            CA_total
            70568.6
Out[45]:
           Dataframe avec la colonne CA
            msno.matrix(merging_erp_web2)
In [46]:
            <Axes: >
Out[46]:
                                                                            Comment statu
                                                                                      post modified
                                                               post date dr
                                           Tating count
                                              average latin
                                                                     post etcerpt
                                                                         Post status
                       price stock districts
                                                 votal sales
                                                     vat status
                                                        post author
                                                           post date
                                                                                                       Post Whe
             1
           Chiffres d'affaires par produit trié par ordre décroissant
            ca_par_produit = merging_erp_web2[['post_name','price','C.A.']]
In [47]:
            ca_par_produit.sort_values(by='C.A.', ascending=False).head(20)
Out[47]:
                                                    post_name
                                                                 price
                                                                          C.A.
            194
                                                                       4704.0
                           champagne-gosset-grand-blanc-de-blanc
                                                                  49.0
             71
                                    champagne-gosset-grand-rose
                                                                  49.0
                                                                       4263.0
            218
                                                                        2288.0
                                             cognac-frapin-vip-xo
                                                                 176.0
             70
                           champagne-gosset-grand-millesime-2006
                                                                  53.0 1590.0
             69
                                gosset-champagne-grande-reserve
                                                                  39.0
                                                                       1560.0
            201
                   champagne-egly-ouriet-grand-cru-brut-blanc-de-...
                                                                 126.5 1391.5
            199
                    champagne-egly-ouriet-grand-cru-millesime-2008
                                                                 225.0 1125.0
             79
                 elian-daros-cotes-du-marmandais-clos-baquey-2015
                                                                  29.0 1044.0
            651
                           domaine-giudicelli-patrimonio-blanc-2019
                                                                  25.2 1033.2
```

16.6 1029.2

gilles-robin-crozes-hermitage-papillon-2019

merging\_erp\_web2.shape

(714, 28)

30

In [43]:

Out[43]:

```
17
                                                          44.3 1018.9
          clos-du-mont-olivet-chateauneuf-du-pape-2012
228
         marc-colin-et-fils-chassagne-montrachet-blanc-...
                                                          43.9 1009.7
373
            jacqueson-rully-blanc-1er-cru-la-pucelle-2018
                                                          27.9 1004.4
445
                                                          59.9
                                                                  958.4
                    albert-mann-pinot-noir-grand-h-2017
652
                domaine-giudicelli-patrimonio-rouge-2016
                                                          25.2
                                                                  932.4
390
          alain-graillot-crozes-hermitage-rouge-la-guira...
                                                           37.2
                                                                  892.8
                                                                  824.5
605
                                                          48.5
             albert-mann-pinot-noir-clos-de-la-faille-2017
 18
       clos-du-mont-olivet-chateauneuf-du-pape-papet-...
                                                           71.6
                                                                  716.0
182
                hauvette-baux-provence-amethyste-2017
                                                           69.8
                                                                  698.0
381
      domaine-des-croix-corton-charlemagne-grand-cru... 137.0
                                                                  685.0
```

```
# Données
In [48]:
         produits = [
             "Champagne Gosset Grand Blanc",
             "Champagne Gosset Grand Rosé",
             "Cognac Frapin VIP XO",
             "Champagne Gosset Grand Millésime 2006",
             "Gosset Champagne Grande Réserve",
             "Champagne Egly-Ouriet Grand Cru Brut Blanc de Blancs",
             "Champagne Egly-Ouriet Grand Cru Millésime 2008",
             "Elian Daros Côtes du Marmandais Clos Baquey 2015",
             "Domaine Giudicelli Patrimonio Blanc 2019",
             "Gilles Robin Crozes-Hermitage Papillon 2019",
             "Clos du Mont Olivet Châteauneuf-du-Pape 2012",
             "Marc Colin et Fils Chassagne-Montrachet Blanc 2018"
         prix = [49.0, 49.0, 176.0, 53.0, 39.0, 126.5, 225.0, 29.0, 25.2, 16.6, 44.3, 43.9]
         chiffre_affaires = [4704.0, 4263.0, 2288.0, 1590.0, 1560.0, 1391.5, 1125.0, 1044.0, 1033
         # Créer un DataFrame
         df = pd.DataFrame({'Produit': produits, 'Prix': prix, 'Chiffre d\'Affaires': chiffre_aff
         # Faire pivoter les noms de produits pour les rendre lisibles
         fig, ax = plt.subplots(figsize=(12, 6))
         ax.bar(df.index, df['Chiffre d\'Affaires'], color='b', alpha=0.7, label='Chiffre d\'Affa
         ax.set_xlabel('Produit')
         ax.set_ylabel('Chiffre d\'Affaires', color='b')
         ax.tick_params(axis='y', labelcolor='b')
         ax.set_xticks(df.index)
         ax.set_xticklabels(df['Produit'], rotation=45, ha='right')
         # Ajouter les prix comme des points sur le graphique
         ax2 = ax.twinx()
         ax2.plot(df.index, df['Prix'], color='r', marker='o', label='Prix')
         ax2.set_ylabel('Prix unitaire', color='r')
         # Titre et légende
         plt.title('Classement du Chiffre d\'Affaires par Produit')
         fig.tight_layout()
         fig.legend(loc='upper right')
         # Afficher le graphique
         plt.show()
```

```
ca_par_produit.dtypes
In [49]:
                       object
         post_name
Out[49]:
         price
                      float64
         C.A.
                      float64
         dtype: object
         gosset_grand_blanc = ca_par_produit[ca_par_produit['C.A.'] == 4704]
In [50]:
         gosset_grand_rose = ca_par_produit[ca_par_produit['C.A.'] == 4263]
         # Convertir la colonne 'C.A.' de gosset_grand_rose en float
         gosset_grand_rose['C.A.'] = gosset_grand_rose['C.A.'].astype(float)
         # Calcule de la part des champagnes gosset par rapport au CA total
         part_du_CA_total = (((gosset_grand_blanc['C.A.'].values + gosset_grand_rose['C.A.'].valu
         # Afficher la part du CA total
         print(f"la part du chiffres d\'affaires des champagnes Gosset Grand Blanc et Grand Rosé
         la part du chiffres d'affaires des champagnes Gosset Grand Blanc et Grand Rosé est de [1
         2.7] %.
         C:\Users\nbous\AppData\Local\Temp\ipykernel_18332\2820164503.py:5: SettingWithCopyWarnin
         A value is trying to be set on a copy of a slice from a DataFrame.
         Try using .loc[row_indexer,col_indexer] = value instead
         See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_
         guide/indexing.html#returning-a-view-versus-a-copy
           gosset_grand_rose['C.A.'] = gosset_grand_rose['C.A.'].astype(float)
In [51]: # Trier par ordre décroissant de prix
         best_ca = ca_par_produit.sort_values(by='C.A.', ascending=False).head(10)
         # Création du graphique à barres avec la palette de couleurs bordeaux
         fig = px.bar(best_ca, x='post_name', y='C.A.', color='C.A.',
                      labels={'post_name': 'Vin', 'C.A.': 'chiffres d\'affaires'},
                      color_discrete_sequence=px.colors.qualitative.Set3) # Utilisation de la pa
         # Personnalisation du graphique
         fig.update_layout(
```

title='Chiffres d\'affaires classé par produit',

xaxis\_title='vin',

```
yaxis_title='CA',
legend_title='Légende',
xaxis_tickangle=-45,
showlegend=False
)

# Ajustement de la taille du graphique et des marges
fig.update_layout(
    autosize=False,
    width=1000,
    height=600,
    margin=dict(l=50, r=50, b=100, t=100) # Ajustement des marges
)

# Affichage du graphique
fig.show()
```

# Analyse univariée : Prix et Outliers

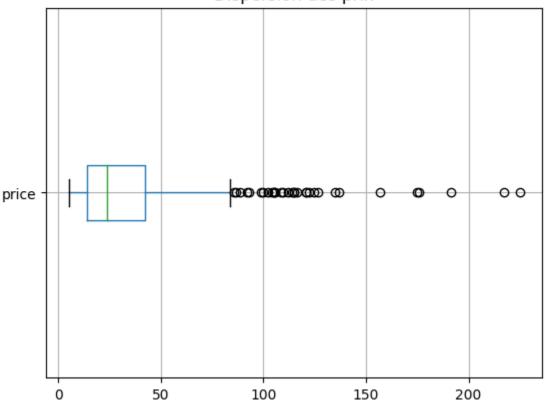
Statistiques descriptives

```
In [52]:
          merging_erp_web2[['price']].describe().round(2)
                  price
Out[52]:
          count 714.00
                  32.49
           mean
            std
                  27.81
            min
                   5.20
            25%
                  14.10
            50%
                  23.55
                  42.18
            75%
            max 225.00
```

# Distribution des prix

```
In [84]: merging_erp_web2.boxplot(column="price", vert=False)
    plt.title('Dispersion des prix')
    plt.show()
```

## Dispersion des prix



## **Outliers**

1/ Méthode Interquartile (IQR) - NumPy

```
In [53]:
         # Calculer les quartiles
         Q1 = np.percentile(merging_erp_web2['price'], 25)
         Q3 = np.percentile(merging_erp_web2['price'], 75)
         IQR = Q3 - Q1
         # Calculer les bornes des outliers
         lower\_bound = Q1 - 1.5 * IQR
         upper\_bound = Q3 + 1.5 * IQR
         # Trouver les outliers
         outliers = merging_erp_web2[(merging_erp_web2['price'] < lower_bound) | (merging_erp_web
         print(f"IQR = {IQR:.2f}")
         print(f"Seuil inférieur pour les outliers = {lower_bound:.2f}")
         print(f"Seuil supérieur pour les outliers = {upper_bound:.2f}")
         print("Outliers :")
         print(outliers) # aucun prix en-dessous du seuil inférieur
         IQR = 28.08
         Seuil inférieur pour les outliers = -28.01
         Seuil supérieur pour les outliers = 84.29
         Outliers:
              product_id onsale_web
                                              stock_quantity stock_status id_web
                                       price
         63
                    4115
                                       100.0
                                                          11
                                                                   instock 15382
         65
                    4132
                                        88.4
                                                           5
                                                                   instock 11668
         199
                    4352
                                    1 225.0
                                                           0
                                                               outofstock 15940
                                                           2
         201
                    4355
                                    1 126.5
                                                                   instock
                                                                           12589
                                                                outofstock
                                                                           13853
         205
                    4359
                                        85.6
                                                           0
         218
                    4402
                                    1
                                      176.0
                                                           8
                                                                   instock
                                                                             3510
         219
                    4404
                                      108.5
                                                           2
                                                                   instock
                                                                             3507
         221
                                                           3
                                                                             7819
                    4406
                                       157.0
                                                                   instock
         222
                    4407
                                       104.0
                                                           6
                                                                   instock
                                                                             3509
```

227	4582	1 1	L09.6	7	instock	12857	
380	4903	1 1	L02.3	20	instock	14805	
381	4904	1 1	L37.0	13	instock	14220	
426	5001	1 2	217.5	20	instock	14581	
431	5007	1 1	L05.0	17	instock	12791	
432	5008	1 1	L05.0	10	instock	11602	
437	5025	1 1	L12.0	Θ	outofstock	13914	
438	5026	1	86.8	2	instock	13913	
502	5565	1	92.0	Θ	outofstock	19822	
511	5612	1 1	L24.8	12	instock	14915	
553	5767	1 1	L75.0	12	instock	15185	
587	5892	1 1	L91.3	10	instock	14983	
602	5916	1	93.0	3	instock	14774	
603	5917	1 1	L22.0	4	instock	14775	
604	5918	1 1	L14.0	8	instock	14773	
642	6126	1 1	L35.0	10	instock	14923	
647	6201	1 1	L05.6	7	instock	14596	
648	6202	1 1	L16.4	14	instock	15126	
653	6212	1 1	L15.0	2	instock	13996	
654	6213	1 1	L21.0	7	instock	15072	
655	6214	1	99.0	7	instock	11601	
656	6215	1 1	L15.0	4	instock	12790	
657	6216	1 1	L21.0	6	instock	15070	
			ating_count			ing_status	
63	0	0	(		0.0	closed	\
65	0	Θ	(		0.0	closed	
199	0	Θ	(		0.0	closed	
201	0	0	(		0.0	closed	
205	0	0	(		0.0	closed	
218	0	Θ	(		0.0	closed	
219	0	Θ	(		0.0	closed	
221	0	0	(		0.0	closed	
222	0	0	(		0.0	closed	
227	0	Θ	(		0.0	closed	
380	0	Θ	(		0.0	closed	
381	0	0	(		0.0	closed	
426	0	0	(		0.0	closed	
431	0	Θ	(		0.0	closed	
432	0	0	(		0.0	closed	
437	0	Θ	(		0.0	closed	
438	0	0	(		0.0	closed	
502	0	0	(		0.0	closed	
511	0	0	(		0.0	closed	
553	0	0	(		0.0	closed	
587	0	0	(		0.0	closed	
602	0	0	(		0.0	closed	
603	0	0	(		0.0	closed	
604	0	0	(		0.0	closed	
642	0	0	(		0.0	closed	
647	0	0	(		0.0	closed	
648	0	0	(		0.0	closed	
653	0	0	(		0.0	closed	
654	0	0	(		0.0	closed	
655	0	0	(		0.0	closed	
656	0	0	(		0.0	closed	
657	0	Θ	(	9	0.0	closed	
				noot =	nmo 555	t modified	
63	zind-humbrecht	-riesling	nc-randen d	post_nann-clos-s		t_modified 8 11:45:02	\
65	zind-humbrecht						`
199					2020-02-2 908 2020-03-0		
201	champagne-egly						
205	champagne-larm						
218	onampayne-tal III	INTIUTEL DELL			2019-12-2 -xo 2020-08-2		
219		CC			-x0 2020-08-2 -x0 2020-08-1		
213		CC	/giiuo = 11 ap.	rii i oiirbaiiot	VO 5050-00-T	~ 03.30.TO	

```
221
        cognac-frapin-chateau-de-fontpinot-1989-20-ans 2020-03-14 16:05:04
222
                             cognac-frapin-cigar-blend 2020-07-04 09:45:03
     chateau-de-puligny-montrachet-1cru-champ-canet... 2020-02-06 16:35:02
227
380
     domaine-des-croix-corton-grand-cru-les-greves-... 2020-06-27 09:00:07
381
     domaine-des-croix-corton-charlemagne-grand-cru... 2020-05-19 17:15:02
426
        david-duband-charmes-chambertin-grand-cru-2014 2020-05-16 09:00:05
431
     domaine-des-comtes-lafon-volnay-1er-cru-santen... 2020-07-02 09:30:03
432
     domaine-des-comtes-lafon-volnay-1er-cru-santen... 2020-06-23 15:35:02
437
     champagne-agrapart-fils-lavizoise-grand-cru-20... 2020-07-09 17:05:02
438
     champagne-agrapart-fils-mineral-extra-brut-bla... 2020-05-11 14:35:02
502
                         tempier-bandol-cabassaou-2017 2020-01-04 13:57:04
511
     domaine-weinbach-gewurztraminer-gc-furstentum-... 2019-01-23 09:33:57
553
                   camille-giroud-clos-de-vougeot-2016 2020-06-11 15:25:04
587
     coteaux-champenois-egly-ouriet-ambonnay-rouge-... 2020-04-01 09:30:09
602
          wemyss-malts-single-cask-chocolate-moka-cake 2019-12-23 09:30:21
603
    wemyss-malts-single-cask-scotch-whisky-choc-n-... 2020-03-11 09:30:09
604
    wemyss-malts-single-cask-scotch-whisky-chai-ca... 2020-07-31 18:25:03
642
                champagne-gosset-celebris-vintage-2007 2020-08-27 11:45:02
647
     david-duband-chambolle-musigny-1er-cru-les-sen... 2020-02-29 15:25:02
648
             domaine-clerget-echezeaux-en-orveaux-2015 2020-06-06 15:45:01
653
     domaine-des-comtes-lafon-volnay-1er-cru-santen... 2020-06-16 09:30:16
654
    domaine-des-comtes-lafon-volnay-1er-cru-santen... 2020-06-25 09:30:06
655
     domaine-des-comtes-lafon-volnay-1er-cru-champa... 2020-07-04 11:35:02
656
     domaine-des-comtes-lafon-volnay-1er-cru-champa... 2019-11-04 09:30:25
     domaine-des-comtes-lafon-volnay-1er-cru-champa... 2020-07-30 09:30:08
657
      post_modified_gmt post_parent
63
   2020-02-08 10:45:02
                                0.0
   2020-02-20 08:55:02
                                0.0
199 2020-03-07 10:18:45
                                0.0
201 2020-08-13 08:15:02
                                0.0
205 2019-12-23 08:30:11
                                0.0
218 2020-08-22 09:35:03
                                0.0
219 2020-08-12 07:30:16
                                0.0
221 2020-03-14 15:05:04
                                0.0
222 2020-07-04 07:45:03
                                0.0
227 2020-02-06 15:35:02
                                0.0
380 2020-06-27 07:00:07
                                0.0
381 2020-05-19 15:15:02
                                0.0
426 2020-05-16 07:00:05
                                0.0
431 2020-07-02 07:30:03
                                0.0
432 2020-06-23 13:35:02
                                0.0
437 2020-07-09 15:05:02
                                0.0
438 2020-05-11 12:35:02
                                0.0
502 2020-01-04 12:57:04
                                0.0
511 2019-01-23 08:33:57
                                0.0
553 2020-06-11 13:25:04
                                0.0
587 2020-04-01 07:30:09
                                0.0
602 2019-12-23 08:30:21
                                0.0
603 2020-03-11 08:30:09
                                0.0
604 2020-07-31 16:25:03
                                0.0
642 2020-08-27 09:45:02
                                0.0
647 2020-02-29 14:25:02
                                0.0
648 2020-06-06 13:45:01
                                0.0
653 2020-06-16 07:30:16
                                0.0
654 2020-06-25 07:30:06
                                0.0
655 2020-07-04 09:35:02
                                0.0
656 2019-11-04 08:30:25
                                0.0
657 2020-07-30 07:30:08
                                0.0
                                                   guid menu_order post_type
    https://www.bottle-neck.fr/?post_type=product&...
63
                                                                     product
                                                               0.0
65
    https://www.bottle-neck.fr/?post_type=product&...
                                                               0.0
                                                                     product
199
    https://www.bottle-neck.fr/?post_type=product&...
                                                               0.0
                                                                     product
201
    https://www.bottle-neck.fr/?post_type=product&...
                                                               0.0
                                                                     product
205
     https://www.bottle-neck.fr/?post_type=product&...
                                                               0.0
                                                                     product
```

218	https://www.hott	le-neck.fr/?post_type=product&	0.0	product
219		le-neck.fr/?post_type=product&		product
221		le-neck.fr/?post_type=product&		product
222		le-neck.fr/?post_type=product&		product
227	-	le-neck.fr/?post_type=product&		product
380		le-neck.fr/?post_type=product&		product
381		le-neck.fr/?post_type=product&		product
426	-	le-neck.fr/?post_type=product&		product
431		le-neck.fr/?post_type=product&		product
432	https://www.bott	le-neck.fr/?post_type=product&	0.0	product
437		le-neck.fr/?post_type=product&		product
438	https://www.bott	le-neck.fr/?post_type=product&	0.0	product
502	-	le-neck.fr/?post_type=product&		product
511		le-neck.fr/?post_type=product&		product
553	-	le-neck.fr/?post_type=product&		product
587		le-neck.fr/?post_type=product&		product
602		le-neck.fr/?post_type=product&		product
603	•	le-neck.fr/?post_type=product&		product
604		le-neck.fr/?post_type=product&		product
642	-	le-neck.fr/?post_type=product&		product
647		le-neck.fr/?post_type=product&		product
648		le-neck.fr/?post_type=product&		product
653	•	le-neck.fr/?post_type=product&		product
654		le-neck.fr/?post_type=product&		product
655		le-neck.fr/?post_type=product& le-neck.fr/?post_type=product&		product
656 657	•	le-neck.fr/?post_type=product& le-neck.fr/?post_type=product&		product product
057	TICLPS.//WWW.DOCC	re-neck.fi/?post_type-producta	0.0	product
	comment_count	C.A.		
63	0.0	0.0		
65	0.0	0.0		
199		25.0		
201		91.5		
205	0.0	85.6		
218	0.0 22	88.0		
219	0.0 2	17.0		
221	0.0	0.0		
222		94.0		
227	0.0	0.0		
380	0.0	0.0		
381		85.0		
426	0.0	0.0		
431	0.0	0.0		
432	0.0	0.0		
437	0.0	0.0		
438 502	0.0 0.0	0.0 0.0		
511	0.0	0.0		
553	0.0	0.0		
587		73.9		
602	0.0	0.0		
603	0.0	0.0		
604	0.0	0.0		
642		70.0		
647	0.0	0.0		
648	0.0	0.0		
653		30.0		
654	0.0	0.0		
655	0.0	0.0		
656	0.0	0.0		
657	0.0	0.0		

[32 rows x 29 columns]

```
In [56]: # Données fournies
         Q1 = merging_erp_web2['price'].quantile(0.25).round(2)
         Q3 = merging_erp_web2['price'].quantile(0.75).round(2)
         IQR = Q3 - Q1
         # Seuils pour les outliers
         lower_bound = Q1 - 1.5 * IQR # juste pour information, mais nous n'avons pas de prix nég
         seuil = Q3 + 1.5 * IQR
         # Données
         data = merging_erp_web2['price']
         # Trouver les outliers
         outliers = [val for val in data if val > seuil]
         not_outliers = [val for val in data if val < seuil]</pre>
         print(f"Seuil supèrieur = {seuil :.2f}")
         print(f"Seuil infèrieur = {lower_bound :.2f}")
         print(f"Outliers : {outliers}")
         print(f"not_outliers: {not_outliers}")
```

Seuil supèrieur = 84.30 Seuil infèrieur = -28.02Outliers: [100.0, 88.4, 225.0, 126.5, 85.6, 176.0, 108.5, 157.0, 104.0, 109.6, 102.3, 1 37.0, 217.5, 105.0, 105.0, 112.0, 86.8, 92.0, 124.8, 175.0, 191.3, 93.0, 122.0, 114.0, 1 35.0, 105.6, 116.4, 115.0, 121.0, 99.0, 115.0, 121.0] not\_outliers: [24.2, 34.3, 20.8, 14.1, 46.0, 34.3, 32.7, 31.2, 60.0, 42.6, 80.0, 18.3, 2 2.8, 19.3, 21.8, 7.7, 33.7, 44.3, 71.6, 12.7, 8.7, 8.7, 8.7, 11.9, 11.9, 14.5, 14.4, 19. 5, 20.8, 22.0, 16.6, 60.0, 23.4, 33.2, 32.0, 77.8, 12.7, 14.7, 14.05, 22.9, 44.0, 37.0, 39.0, 17.0, 23.2, 19.0, 16.4, 14.4, 13.7, 12.6, 22.8, 12.8, 22.1, 12.8, 15.8, 15.8, 16. 3, 16.3, 9.7, 6.8, 12.6, 35.0, 31.7, 23.0, 29.8, 25.7, 77.4, 39.0, 53.0, 49.0, 29.5, 33. 0, 37.5, 69.0, 59.0, 13.7, 19.2, 29.0, 9.8, 14.5, 20.35, 12.0, 18.5, 9.3, 9.3, 11.6, 14. 3, 10.8, 7.6, 12.0, 20.5, 14.3, 18.2, 9.0, 7.8, 5.7, 5.7, 5.7, 13.5, 13.5, 11.5, 24.0, 2 4.0, 11.9, 16.7, 21.4, 16.6, 13.3, 9.5, 12.1, 9.3, 17.8, 13.5, 10.8, 27.2, 9.4, 5.8, 5. 8, 38.0, 38.0, 9.9, 11.3, 23.0, 6.7, 7.6, 79.8, 48.5, 39.8, 58.8, 26.5, 13.4, 17.1, 16. 7, 11.6, 12.8, 8.9, 9.7, 17.2, 16.9, 12.6, 29.9, 9.6, 11.1, 11.1, 17.1, 28.0, 28.0, 8.9, 8.6, 13.5, 8.9, 15.3, 14.8, 19.5, 14.1, 59.6, 26.9, 24.4, 31.7, 32.1, 12.2, 9.9, 15.8, 1 5.8, 17.8, 9.6, 19.0, 15.2, 10.2, 15.5, 16.6, 9.2, 12.9, 14.9, 17.6, 24.8, 18.9, 11.6, 2 7.0, 41.0, 69.8, 38.6, 26.7, 19.0, 23.2, 39.1, 44.0, 17.5, 30.0, 8.1, 10.7, 10.9, 49.0, 35.5, 83.0, 59.0, 79.5, 79.5, 51.6, 39.0, 77.0, 49.5, 49.5, 49.5, 57.0, 59.8, 27.5, 62. 0, 59.0, 59.0, 59.0, 44.0, 62.5, 68.1, 28.1, 21.7, 28.5, 67.2, 43.9, 61.6, 41.8, 26.5, 1 6.1, 31.5, 31.5, 49.0, 32.2, 50.1, 13.4, 11.8, 13.1, 26.2, 20.6, 16.9, 19.0, 24.0, 57.0, 67.5, 30.6, 59.0, 11.9, 16.5, 52.4, 52.9, 58.3, 39.6, 52.4, 62.4, 76.8, 50.0, 52.4, 41. 0, 62.4, 50.0, 21.5, 28.5, 24.3, 16.5, 25.3, 49.0, 36.2, 33.4, 40.2, 43.0, 43.0, 48.8, 2 0.8, 16.4, 14.4, 21.0, 12.3, 20.2, 17.0, 21.9, 17.8, 19.8, 19.0, 10.7, 12.9, 9.5, 29.8, 13.2, 6.3, 7.1, 9.1, 9.1, 18.1, 14.0, 30.1, 12.8, 12.8, 19.8, 18.2, 31.6, 16.8, 22.8, 3 2.6, 44.0, 55.4, 15.8, 18.4, 13.3, 11.1, 18.6, 23.4, 18.2, 12.5, 15.9, 13.7, 29.0, 23.4, 12.7, 26.0, 29.5, 8.6, 14.3, 22.0, 16.8, 15.3, 7.4, 9.7, 14.5, 11.9, 16.4, 27.9, 12.0, 7.4, 26.5, 24.3, 16.9, 6.8, 13.9, 7.8, 13.7, 9.8, 29.5, 28.5, 10.1, 12.1, 12.3, 11.1, 1 1.1, 13.6, 21.0, 18.7, 41.6, 12.0, 78.0, 14.9, 6.5, 8.7, 8.5, 9.9, 8.2, 9.8, 9.9, 9.3, 2 2.8, 18.7, 28.4, 27.9, 25.3, 17.0, 27.9, 20.1, 27.9, 21.2, 20.8, 41.0, 46.0, 22.9, 53.2, 25.9, 17.3, 25.9, 28.0, 25.9, 25.9, 37.2, 24.4, 24.4, 7.0, 12.8, 23.2, 7.9, 6.5, 7.9, 1 6.7, 17.5, 27.8, 25.7, 18.4, 22.2, 11.1, 9.9, 12.5, 12.9, 20.5, 25.0, 11.3, 7.0, 12.1, 7.1, 49.5, 23.0, 23.7, 16.45, 16.3, 18.5, 26.5, 78.0, 78.0, 78.0, 27.3, 64.9, 48.7, 59. 4, 48.7, 55.6, 9.3, 19.8, 45.0, 62.1, 22.5, 7.5, 52.6, 45.0, 67.0, 59.9, 59.9, 65.0, 15. 2, 19.0, 11.1, 18.0, 22.8, 19.5, 28.8, 16.1, 24.2, 35.3, 10.7, 12.7, 17.1, 24.0, 39.0, 1 3.2, 23.6, 15.5, 16.3, 16.2, 7.2, 54.8, 42.0, 19.8, 10.2, 10.4, 11.5, 17.9, 21.6, 33.4, 49.5, 43.5, 43.5, 26.5, 13.8, 18.2, 12.9, 38.6, 48.4, 60.4, 38.6, 12.0, 61.6, 65.9, 15. 2, 24.6, 48.8, 34.3, 36.3, 57.7, 38.0, 58.0, 58.0, 30.8, 27.5, 34.7, 59.6, 83.7, 30.5, 3 8.6, 18.0, 63.4, 19.2, 19.2, 56.4, 38.4, 27.8, 71.3, 71.3, 25.0, 10.3, 28.0, 44.6, 13.0, 12.7, 6.5, 17.5, 29.9, 44.5, 29.4, 16.9, 19.8, 10.3, 10.8, 31.7, 25.0, 57.6, 13.7, 7.1, 14.9, 11.0, 14.6, 10.7, 73.3, 42.1, 57.0, 24.5, 10.1, 42.2, 13.1, 19.5, 12.9, 35.6, 35. 6, 33.6, 34.4, 38.4, 29.7, 32.8, 5.7, 5.8, 5.8, 21.7, 23.0, 12.5, 17.2, 40.2, 24.0, 23. 8, 17.1, 25.0, 17.4, 27.3, 17.9, 24.0, 16.6, 16.9, 57.6, 63.5, 56.0, 63.5, 41.2, 55.0, 5 7.0, 19.3, 19.0, 26.6, 15.4, 24.7, 28.1, 18.25, 35.1, 27.3, 18.8, 43.9, 19.8, 17.7, 57.

0, 36.0, 36.0, 48.5, 49.5, 14.1, 59.9, 46.0, 74.5, 17.2, 8.7, 15.4, 12.7, 30.0, 13.5, 1 6.3, 56.3, 71.5, 69.0, 17.9, 48.5, 71.7, 8.5, 10.9, 21.8, 38.5, 9.3, 13.6, 24.5, 12.6, 1 3.4, 29.8, 36.9, 40.7, 33.2, 34.8, 74.8, 62.4, 46.0, 39.2, 10.6, 10.6, 5.2, 46.0, 31.0, 20.2, 25.2, 25.2, 23.5, 26.4, 26.7, 20.4, 20.4, 40.2, 9.0, 45.9, 10.4, 78.0, 40.5, 27.9, 22.4, 28.4, 72.0, 29.0, 29.2, 44.0, 68.3, 41.8, 40.0, 13.5, 19.0, 24.4, 32.8, 15.4, 9.9, 13.5, 51.0, 35.2, 42.2, 33.2, 41.8, 32.2, 37.7, 47.2, 52.7, 22.4, 50.4, 35.6, 27.7, 48. 5, 15.4, 46.5, 46.5, 46.5, 42.0, 21.8, 50.5, 49.9, 19.0, 8.4, 27.5, 69.0, 54.8, 16.3]

3/ Méthode interquartile avec package scipy

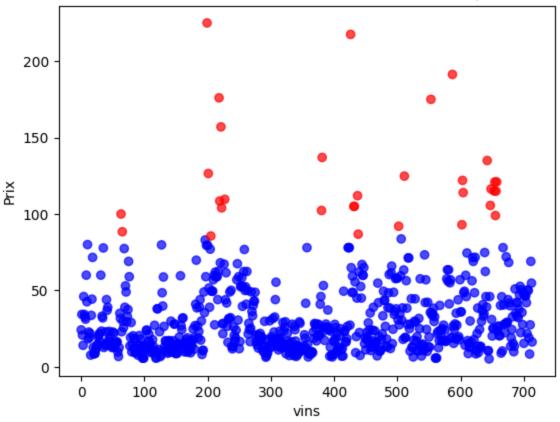
```
In [59]: from scipy.stats import iqr
         # Calculer l'IQR
         data = merging_erp_web2['price']
         iqr_value = iqr(data)
         # Calculer les bornes des outliers
         Q1 = data.quantile(0.25)
         Q3 = data.quantile(0.75)
         lower_bound = Q1 - 1.5 * iqr_value
         upper_bound = Q3 + 1.5 * iqr_value
         # Trouver les outliers
         outliers = data[(data < lower_bound) | (data > upper_bound)]
         print(f"IQR = {iqr_value:.2f}")
         print(f"Borne inférieure pour les outliers = {lower_bound:.2f}")
         print(f"Borne supérieure pour les outliers = {upper_bound:.2f}")
         print(f"Outliers : {outliers.tolist()}")
         IQR = 28.08
         Borne inférieure pour les outliers = -28.01
         Borne supérieure pour les outliers = 84.29
         Outliers: [100.0, 88.4, 225.0, 126.5, 85.6, 176.0, 108.5, 157.0, 104.0, 109.6, 102.3, 1
         37.0, 217.5, 105.0, 105.0, 112.0, 86.8, 92.0, 124.8, 175.0, 191.3, 93.0, 122.0, 114.0, 1
         35.0, 105.6, 116.4, 115.0, 121.0, 99.0, 115.0, 121.0]
         Visuel avec Matplotlib
```

```
In [60]: # Données fournies
         Q1 = merging_erp_web2['price'].quantile(0.25).round(2)
         Q3 = merging_erp_web2['price'].quantile(0.75).round(2)
         IQR = Q3 - Q1
         # Seuils pour les outliers
         seuil = 03 + 1.5 * IQR
         # Données (remplacez cela par vos données)
         data = merging_erp_web2['price']
         # Initialisation des listes pour les couleurs
         colors = []
         # Attribution des couleurs en fonction de la position par rapport au seuil
         for val in data:
             if val > seuil:
                 colors.append('red') # Au-dessus du seuil
             else:
                 colors.append('blue') # En-dessous du seuil
         # Création du scatter plot
         plt.scatter(range(len(data)), data, color=colors, alpha=0.7)
         # Ajout des étiquettes
         plt.xlabel('vins')
```

```
plt.ylabel('Prix')
plt.title('Scatter Plot des Prix en fonction du seuil IQR')

# Affichage du graphique
plt.show()
```

## Scatter Plot des Prix en fonction du seuil IQR



## Visuel avec Plotly

```
In [61]: # Données fournies
         Q1 = merging_erp_web2['price'].quantile(0.25).round(2)
         Q3 = merging_erp_web2['price'].quantile(0.75).round(2)
         IQR = Q3 - Q1
         # Seuils pour les outliers
         seuil = Q3 + 1.5 * IQR
         print(IQR)
         print(seuil)
         # Données (remplacez cela par vos données)
         data = merging_erp_web2
         # Attribution des couleurs en fonction de la position par rapport au seuil
         colors = ['> IQR' if val > seuil else '< IQR' for val in data['price']]</pre>
         # Création du scatter plot avec Plotly
         fig = px.scatter(data, x=data.index, y='price', color=colors, labels={'color': 'Position'}
         # Personnalisation du graphique
         fig.update_traces(marker=dict(size=5, opacity=0.7))
         fig.update_layout(
             title='Dispersion des Prix en fonction du seuil Interquartile',
             xaxis_title='Index',
             yaxis_title='Prix'
         )
```

```
# Affichage du graphique
         fig.show()
         28.08
         84.3
In [62]: # Données fournies
         Q1 = merging_erp_web2['price'].quantile(0.25).round(2)
         Q3 = merging_erp_web2['price'].quantile(0.75).round(2)
         IQR = Q3 - Q1
         # Seuils pour les outliers
         seuil = 03 + 1.5 * IQR
         # Données
         data = merging_erp_web2
         # Sélectionnez les vins au-dessus du seuil
         above_threshold = data[data['price'] > seuil]
         # Trier par ordre décroissant de prix
         above_threshold = above_threshold.sort_values(by='price', ascending=False).head(10)
         # Création du graphique à barres avec la palette de couleurs bordeaux
         fig = px.bar(above_threshold, x='post_name', y='price', color='price',
                       labels={'post_name': 'Nom du Vin', 'price': 'Prix'},
                       color_discrete_sequence=px.colors.qualitative.Set3) # Utilisation de la pa
         # Personnalisation du graphique
         fig.update_layout(
             title='Vins de prestige au-dessus du seuil IQR (Triés par Prix décroissant)',
             xaxis_title='Nom du Vin',
             yaxis_title='Prix',
             legend_title='Vin',
             xaxis_tickangle=-45,
             showlegend=False
         # Ajustement de la taille du graphique et des marges
         fig.update_layout(
             autosize=False,
             width=1000,
             height=600,
             margin=dict(l=50, r=50, b=100, t=100) # Ajustement des marges
         )
         # Affichage du graphique
         fig.show()
         above_threshold = len(data[data['price'] > seuil])
In [63]:
         print(f"Il y a {above_threshold} outliers (valeurs atypiques).")
         Il y a 32 outliers (valeurs atypiques).
         A/ Z-SCORE
         1/ Méthode classique
In [65]: # Calculer le Z-score
         mean = merging_erp_web2['price'].mean()
         std_ = merging_erp_web2['price'].std()
```

```
merging_erp_web2['Z-Score'] = (merging_erp_web2['price'] - mean) / std_

# Définir un seuil de 2 pour identifier les valeurs aberrantes
threshold = 2
outliers = merging_erp_web2[abs(merging_erp_web2['Z-Score']) > threshold]

top_outliers_ = outliers[['post_name', 'price', 'Z-Score']].sort_values(by='Z-Score', as top_outliers_
```

Out[65]:

	post_name	price	Z-Score
199	champagne-egly-ouriet-grand-cru-millesime-2008	225.0	6.922087
426	david-duband-charmes-chambertin-grand-cru-2014	217.5	6.652405
587	$coteaux\hbox{-}champenois\hbox{-}egly\hbox{-}ouriet\hbox{-}ambonnay\hbox{-}rouge\hbox{-}$	191.3	5.710315
218	cognac-frapin-vip-xo	176.0	5.160164
553	camille-giroud-clos-de-vougeot-2016	175.0	5.124206
221	cognac-frapin-chateau-de-fontpinot-1989-20-ans	157.0	4.476969
381	domaine-des-croix-corton-charlemagne-grand-cru	137.0	3.757817
642	champagne-gosset-celebris-vintage-2007	135.0	3.685902
201	champagne-egly-ouriet-grand-cru-brut-blanc-de	126.5	3.380262
511	$domaine-we in bach-gewurzt raminer-gc-fursten tum-\dots\\$	124.8	3.319134
603	wemyss-malts-single-cask-scotch-whisky-choc-n	122.0	3.218453
657	domaine-des-comtes-la fon-volnay-1er-cru-champa	121.0	3.182495
654	domaine-des-comtes-lafon-volnay-1er-cru-santen	121.0	3.182495
648	domaine-clerget-echezeaux-en-orveaux-2015	116.4	3.017090
656	domaine-des-comtes-lafon-volnay-1er-cru-champa	115.0	2.966750
653	domaine-des-comtes-lafon-volnay-1er-cru-santen	115.0	2.966750
604	wemyss-malts-single-cask-scotch-whisky-chai-ca	114.0	2.930792
437	champagne-agrapart-fils-lavizoise-grand-cru-20	112.0	2.858877
227	chateau-de-puligny-montrachet-1cru-champ-canet	109.6	2.772578
219	cognac-frapin-fontpinot-xo	108.5	2.733025
647	david-duband-chambolle-musigny-1er-cru-les-sen	105.6	2.628748
432	domaine-des-comtes-lafon-volnay-1er-cru-santen	105.0	2.607173
431	domaine-des-comtes-lafon-volnay-1er-cru-santen	105.0	2.607173
222	cognac-frapin-cigar-blend	104.0	2.571216
380	domaine-des-croix-corton-grand-cru-les-greves	102.3	2.510088
63	zind-humbrecht-riesling-gc-rangen-thann-clos-s	100.0	2.427385
655	domaine-des-comtes-lafon-volnay-1er-cru-champa	99.0	2.391428
602	wemyss-malts-single-cask-chocolate-moka-cake	93.0	2.175682
502	tempier-bandol-cabassaou-2017	92.0	2.139725
65	zind-humbrecht-pinot-gris-grand-cru-rangen-de	88.4	2.010277

```
In [85]: len(top_outliers_)
```

#### 2/ Méthode package Scikit Learn

```
In [66]: from sklearn.preprocessing import StandardScaler
    # Créer un objet StandardScaler
    scaler = StandardScaler()
    # Calculer les Z-scores
    merging_erp_web2['Z-Score'] = scaler.fit_transform(merging_erp_web2[['price']])

# Définir un seuil de 2 pour identifier les valeurs aberrantes
    threshold = 2
    outliers = merging_erp_web2[abs(merging_erp_web2['Z-Score']) > threshold]

top_outliers = outliers[['post_name', 'price', 'Z-Score']].sort_values(by='Z-Score', asc top_outliers)
```

	top_	_outliers	·	
Out[66]:		post_name	price	Z-Score
	199	champagne-egly-ouriet-grand-cru-millesime-2008	225.0	6.926939
	426	david-duband-charmes-chambertin-grand-cru-2014	217.5	6.657068
	587	coteaux-champenois-egly-ouriet-ambonnay-rouge	191.3	5.714318
	218	cognac-frapin-vip-xo	176.0	5.163781
	553	camille-giroud-clos-de-vougeot-2016	175.0	5.127798
	221	cognac-frapin-chateau-de-fontpinot-1989-20-ans	157.0	4.480108
	381	domaine-des-croix-corton-charlemagne-grand-cru	137.0	3.760451
	642	champagne-gosset-celebris-vintage-2007	135.0	3.688486
	201	champagne-egly-ouriet-grand-cru-brut-blanc-de	126.5	3.382632
	511	$domaine-we in bach-gewurzt raminer-gc-fursten tum-\dots\\$	124.8	3.321461
	603	wemyss-malts-single-cask-scotch-whisky-choc-n	122.0	3.220709
	657	domaine-des-comtes-la fon-volnay-1er-cru-champa	121.0	3.184726
	654	domaine-des-comtes-lafon-volnay-1er-cru-santen	121.0	3.184726
	648	domaine-clerget-echezeaux-en-orveaux-2015	116.4	3.019205
	656	domaine-des-comtes-lafon-volnay-1er-cru-champa	115.0	2.968829
	653	domaine-des-comtes-lafon-volnay-1er-cru-santen	115.0	2.968829
	604	wemyss-malts-single-cask-scotch-whisky-chai-ca	114.0	2.932846
	437	champagne-agrapart-fils-lavizoise-grand-cru-20	112.0	2.860881
	227	chateau-de-puligny-montrachet-1cru-champ-canet	109.6	2.774522
	219	cognac-frapin-fontpinot-xo	108.5	2.734941
	647	david-duband-chambolle-musigny-1er-cru-les-sen	105.6	2.630591
	432	domaine-des-comtes-lafon-volnay-1er-cru-santen	105.0	2.609001
	431	domaine-des-comtes-lafon-volnay-1er-cru-santen	105.0	2.609001
	222	cognac-frapin-cigar-blend	104.0	2.573018
	380	domaine-des-croix-corton-grand-cru-les-greves	102.3	2.511848
	63	zind-humbrecht-riesling-gc-rangen-thann-clos-s	100.0	2.429087
	655	domaine-des-comtes-lafon-volnay-1er-cru-champa	99.0	2.393104

wemyss-malts-single-cask-chocolate-moka-cake

93.0 2.177207

602

```
tempier-bandol-cabassaou-20172.141225zind-humbrecht-pinot-gris-grand-cru-rangen-de-...88.42.011686
```

### 3/ Méthode avec le package scipy

```
In [67]: from scipy.stats import zscore

# Calculer les Z-scores
merging_erp_web2['Z-Score'] = zscore(merging_erp_web2['price'])

# Définir un seuil de 2 pour identifier les valeurs aberrantes
threshold = 2
outliers = merging_erp_web2[abs(merging_erp_web2['Z-Score']) > threshold]

top_32_outliers = outliers[['post_name', 'price', 'Z-Score']].sort_values(by='Z-Score', top_32_outliers)
```

99.0 2.393104

93.0 2.177207

	top_	_32_outliers		·
t[67]:		post_name	price	Z-Score
	199	champagne-egly-ouriet-grand-cru-millesime-2008	225.0	6.926939
	426	david-duband-charmes-chambertin-grand-cru-2014	217.5	6.657068
	587	coteaux-champenois-egly-ouriet-ambonnay-rouge	191.3	5.714318
	218	cognac-frapin-vip-xo	176.0	5.163781
	553	camille-giroud-clos-de-vougeot-2016	175.0	5.127798
	221	cognac-frapin-chateau-de-fontpinot-1989-20-ans	157.0	4.480108
	381	domaine-des-croix-corton-charlemagne-grand-cru	137.0	3.760451
	642	champagne-gosset-celebris-vintage-2007	135.0	3.688486
	201	champagne-egly-ouriet-grand-cru-brut-blanc-de	126.5	3.382632
	511	domaine-weinbach-gewurztraminer-gc-furstentum	124.8	3.321461
	603	wemyss-malts-single-cask-scotch-whisky-choc-n	122.0	3.220709
	657	domaine-des-comtes-lafon-volnay-1er-cru-champa	121.0	3.184726
	654	domaine-des-comtes-lafon-volnay-1er-cru-santen	121.0	3.184726
	648	domaine-clerget-echezeaux-en-orveaux-2015	116.4	3.019205
	656	domaine-des-comtes-lafon-volnay-1er-cru-champa	115.0	2.968829
	653	domaine-des-comtes-lafon-volnay-1er-cru-santen	115.0	2.968829
	604	wemyss-malts-single-cask-scotch-whisky-chai-ca	114.0	2.932846
	437	champagne-agrapart-fils-lavizoise-grand-cru-20	112.0	2.860881
	227	chateau-de-puligny-montrachet-1cru-champ-canet	109.6	2.774522
	219	cognac-frapin-fontpinot-xo	108.5	2.734941
	647	david-duband-chambolle-musigny-1er-cru-les-sen	105.6	2.630591
	432	domaine-des-comtes-lafon-volnay-1er-cru-santen	105.0	2.609001
	431	domaine-des-comtes-lafon-volnay-1er-cru-santen	105.0	2.609001
	222	cognac-frapin-cigar-blend	104.0	2.573018
	380	domaine-des-croix-corton-grand-cru-les-greves	102.3	2.511848
	63	zind-humbrecht-riesling-gc-rangen-thann-clos-s	100.0	2.429087
	CEE	domaina daa aamtaa lafan yalnay 1 ar arri aharraa	000	2 202104

**655** domaine-des-comtes-lafon-volnay-1er-cru-champa...

wemyss-malts-single-cask-chocolate-moka-cake

602

```
tempier-bandol-cabassaou-20172.141225zind-humbrecht-pinot-gris-grand-cru-rangen-de-...88.42.011686
```

#### Z-Score Boxplot - Détermination du seuil

```
In [68]: merging_erp_web2[['Z-Score']].boxplot()
Out[68]: <Axes: >
```

Z-Score

### Analyses complémentaires

-1

```
In [82]: best_sales = merging_erp_web2.groupby(['post_title','price']).agg({'total_sales':'sum'})
best_sales
```

Out[82]: total\_sales

post\_title price

Champagne Gosset Grand Blanc de Blancs	49.0	96.0
Champagne Gosset Grand Rosé	49.0	87.0
Gilles Robin Crozes-Hermitage Rouge Papillon 2019	16.6	62.0
Moulin de Gassac IGP Pays d'Hérault Guilhem Rosé 2019	5.8	46.0
Maurel Pays d'Oc Chardonnay 2019	5.7	43.0
Le Pas de l'Escalette Languedoc Les Petits Pas 2019	13.3	42.0
Domaine Giudicelli Patrimonio Blanc 2019	25.2	41.0
Champagne Gosset Grande Réserve	39.0	40.0
Emile Boeckel Crémant Brut Blanc de Blancs	8.6	38.0
Château de La Liquière Faugères L'Ampoule 2019	10.9	38.0
Domaine Giudicelli Patrimonio Rouge 2016	25.2	37.0
Jacqueson Rully Blanc 1er Cru La Pucelle 2018	27.9	36.0
Elian Daros Côtes du Marmandais Clos Baquey 2015	29.0	36.0
Triennes IGP Méditerranée Rosé 2019	9.3	33.0
Albert Mann Muscat 2018	16.8	32.0
Champagne Gosset Grand Millésime 2006	53.0	30.0
Domaine Saint-Denis Bourgogne Rouge Clos de la Coque 2018	19.5	30.0
Philippe Nusswitz Duché d'Uzès Orénia Rouge 2017	8.5	29.0
Château Turcaud Entre-Deux-Mers 2019	7.1	26.0
Maurel Pays d'Oc Merlot 2018	5.8	24.0

In [90]: # Trier les données par total\_sales pour obtenir les meilleures ventes des valeurs atypi
vins\_les\_plus\_chers = merging\_erp\_web2[['post\_title','price','total\_sales']].sort\_values
vins\_les\_plus\_chers = vins\_les\_plus\_chers[vins\_les\_plus\_chers['price'] > 84]
vins\_les\_plus\_chers.sort\_values(by='total\_sales', ascending=False)

ut[90]:		post_title	price	total_sales
	218	Cognac Frapin VIP XO	176.0	13.0
	201	Champagne Egly-Ouriet Grand Cru Blanc de Noirs	126.5	11.0
	199	Champagne Egly-Ouriet Grand Cru Millésimé 2008	225.0	5.0
	381	Domaine Des Croix Corton Charlemagne Grand Cru	137.0	5.0
	587	Coteaux Champenois Egly-Ouriet Ambonnay Rouge	191.3	3.0
	653	Domaine des Comtes Lafon Volnay 1er Cru Santen	115.0	2.0
	219	Cognac Frapin Château de Fontpinot XO	108.5	2.0
	642	Champagne Gosset Célébris Vintage 2007	135.0	2.0
	222	Cognac Frapin Cigar Blend	104.0	1.0
	205	Champagne Larmandier-Bernier Grand Cru Les Che	85.6	1.0
	603	Wemyss Malts Single Cask Scotch Whisky Choc 'n	122.0	0.0
	654	Domaine des Comtes Lafon Volnay 1er Cru Santen	121.0	0.0
	438	Champagne Agrapart & Extra Br	86.8	0.0
	65	Zind-Humbrecht Pinot Gris Grand Cru Rangen De	88.4	0.0
	502	Tempier Bandol Cabassaou 2017	92.0	0.0
	602	Wemyss Malts Single Cask Scotch Whisky Chocola	93.0	0.0

```
0.0
655
     Domaine des Comtes Lafon Volnay 1er Cru Champa...
                                                         99.0
 63
       Zind-Humbrecht Riesling Grand Cru Rangen De Th... 100.0
                                                                       0.0
380
       Domaine Des Croix Corton Grand Cru Les Grèves ...
                                                        102.3
                                                                       0.0
553
                    Camille Giroud Clos de Vougeot 2016 175.0
                                                                       0.0
432
       Domaine des Comtes Lafon Volnay 1er Cru Santen... 105.0
                                                                       0.0
431
                                                                       0.0
       Domaine des Comtes Lafon Volnay 1er Cru Santen... 105.0
647
      David Duband Chambolle-Musigny 1er Cru Les Sen... 105.6
                                                                       0.0
221
       Cognac Frapin Château de Fontpinot 1989 20 Ans... 157.0
                                                                       0.0
227
        Château de Meursault Puligny-Montrachet 1er Cr... 109.6
                                                                       0.0
437
        Champagne Agrapart & Discrete Extra... 112.0
                                                                       0.0
426
       David Duband Charmes-Chambertin Grand Cru 2014 217.5
                                                                       0.0
511
     Domaine Weinbach Gewurztraminer Grand Cru Furs... 124.8
                                                                       0.0
     Domaine des Comtes Lafon Volnay 1er Cru Champa... 115.0
                                                                       0.0
648
      Domaine Clerget Echezeaux Grand Cru En Orveaux... 116.4
                                                                       0.0
657
     Domaine des Comtes Lafon Volnay 1er Cru Champa... 121.0
                                                                       0.0
604
      Wemyss Malts Single Cask Scotch Whisky Chai Ca... 114.0
                                                                       0.0
```

```
In [91]: # compter les lignes dont les valeurs ne sont pas des zéros
np.count_nonzero(vins_les_plus_chers['total_sales'])
```

Out[91]:

10 vins prestigieux représentent des ventes

```
In [97]:
         import plotly.graph_objects as go
         # Sélectionner les 10 meilleures ventes
         top_10_sales = vins_les_plus_chers.sort_values(by='total_sales', ascending=False).head(1
         # Créer le graphique
         fig = go.Figure()
         # Créer une liste de couleurs en fonction de la meilleure vente
         colors = ['red' if row.equals(top_10_sales.iloc[0]) else 'green' for _, row in top_10_sales.iloc[0])
         # Ajouter les barres pour les meilleures ventes
         fig.add_trace(go.Bar(
             x=top_10_sales['post_title'],
             y=top_10_sales['total_sales'],
             marker_color=colors,
             textposition='outside'
         ))
         # Mise en page du graphique
         fig.update_layout(
             title='Classement des meilleures Ventes parmi les Outliers',
             xaxis_title='Nom du Vin',
             yaxis_title='Ventes Totales',
             xaxis_tickangle=-45, # Inclinaison des étiquettes pour une meilleure lisibilité
             font=dict(size=10) # Réduire la taille de la police
          )
```

# Affichage du graphique
fig.show()